

Analítica de la salud cardíaca mediante PySpark, SQL y aprendizaje automático en Databricks

Romel Rodríguez, Daniel Bravo, Rolando Barria, Frida Leis y Joshep Pineda

Universidad Tecnológica de Panamá

Facultad de Ingeniería de Sistemas Computacionales

Asignatura: Análisis de Datos y Toma de Decisiones para Computación

Profesor Javier Sánchez Galán | Grupo IIL-133 | I semestre de 2026

Resumen— Este artículo presenta un flujo de analítica de datos de extremo a extremo aplicado al conjunto Heart Disease (UCI) en Databricks. Se integraron PySpark y SQL para la ingesta, depuración, exploración y visualización de 303 registros. Como componente de analítica avanzada se entrenó un clasificador Random Forest multiclase, con una exactitud de 61.40 % y un F1 ponderado de 58.95 %. Los resultados muestran que la frecuencia cardíaca máxima, el tipo de dolor de pecho y la depresión del segmento ST son las variables de mayor influencia. El dashboard resume indicadores y patrones de riesgo clínico útiles para apoyar decisiones diagnósticas, sin sustituir la evaluación médica profesional.

Palabras clave

Databricks, PySpark, SQL, Heart Disease, Random Forest, dashboard.

I. INTRODUCCIÓN

La analítica de datos permite transformar mediciones clínicas en información útil para la toma de decisiones. El conjunto Heart Disease (Cleveland) contiene muestras diseñadas para estudiar la relación entre variables clínicas y el diagnóstico de enfermedad cardíaca. El objetivo fue implementar un proceso reproducible en Databricks que incluyera carga, limpieza, análisis exploratorio, consultas SQL, visualización y clasificación.

II. DATOS Y PREPARACIÓN

El archivo heart_disease_clean.csv contiene 303 observaciones y 14 atributos. La ingesta se realizó con Spark usando inferencia de esquema. Se verificaron tipos de datos y estadísticas descriptivas. Se imputaron valores faltantes

mediante la mediana y la tabla limpia se registró como heart_disease.

III. ANÁLISIS EXPLORATORIO Y SQL

Se realizaron agregaciones con PySpark y consultas SQL para identificar distribuciones y promedios por nivel de enfermedad. Los hombres presentaron mayor proporción de enfermedad y el colesterol promedio aumentó con la edad.

IV. DISEÑO DEL DASHBOARD

Se diseñó un dashboard con indicadores y gráficos sobre riesgo por sexo, edad, colesterol, presión arterial y tipo de dolor de pecho, incluyendo filtros para facilitar el análisis.

V. ANALÍTICA AVANZADA

Se entrenó un RandomForestClassifier con división 80/20 y 200 árboles. Se obtuvo una exactitud de 0.614 y un F1 ponderado de 0.59. Las variables más importantes fueron thalach, cp y oldpeak.

VI. RESULTADOS Y DISCUSIÓN

El modelo identifica adecuadamente las clases principales, aunque disminuye su rendimiento en las categorías con menos ejemplos debido al desbalance del conjunto de datos.

VII. CONCLUSIONES





El proyecto integra ingesta, limpieza, análisis, SQL, dashboard y aprendizaje automático en un flujo reproducible. Como trabajo futuro se propone aplicar balanceo de clases, validación cruzada y modelos más avanzados.

REFERENCIAS

[1] UCI Machine Learning Repository.
[2] Databricks Documentation.
[3] Apache Spark Documentation.
[4] Pandas User Guide.
[5] Scikit-learn Documentation

Resultados gráficos y síntesis del dashboard

Figuras generadas a partir de la tabla limpia y de las salidas de los modelos.
Análisis de Datos y Toma de Decisiones para Computación





303
PACIENTES ANALIZADOS



54.4 años
EDAD PROMEDIO



54 %
PACIENTES CON ENFERMEDAD



246 mg/dL
COLESTEROL PROMEDIO

61.40 %

EXACTITUD

57.77 %

PRECISIÓN PONDERADA

61.40 %

RECALL

58.95 %

F1 PONDERADO

Interpretación: El clasificador Random Forest identifica de manera adecuada los principales niveles de riesgo cardiovascular presentes en el conjunto Heart Disease. Aunque el rendimiento disminuye en las clases con menor representación debido al desbalance del conjunto de datos, el dashboard facilita la visualización de indicadores clínicos, patrones de riesgo y variables relevantes, permitiendo que usuarios técnicos y no técnicos interpreten los resultados de forma sencilla y apoyen el proceso de toma de decisiones.